

Sci-Evo 类型

SciEvo-Lineage

面向 AI4Science 的 Sci-Evo 类型科研演化数据集

13,050

结构化记录

4

层数据结构

38

完整样例

10

原始来源样例

GitHub: <https://github.com/Geniusyingmanji/idea-data>

数据 CC-BY-4.0 | 代码 MIT | 基于公开论文和开放摘要构建

为什么需要科学演化数据

传统摘要/引用数据

保留标题、摘要、引用边，但缺少实验决策过程。
难以回答为什么下一篇论文要这样改。

单篇实验轨迹

能描述一篇论文内部步骤，但缺少跨论文演化关系。
难以表示领域问题如何持续推进。

SciEvo-Lineage

同时记录 intra-paper 闭环和 inter-paper 演化。
显式建模 gap -> hypothesis -> decision -> validation。

核心目标：让模型学习科学想法如何在真实论文链中被提出、验证、失败和修正。

数据集总览

L1 PaperAtom

6,010

单篇论文的科研闭环

L2 TransitionAtom

3,057

A->B 论文边的决策叙事

L3 LineageTrajectory

1,515

多论文链的领域演化

L4 AgenticEpisode

2,468

科研 Agent 的 ReAct 轨迹

统一 envelope

release/data/full_dataset.jsonl.gz 中每行均为 {layer, id, data} , 也提供 4 个 layer_*.jsonl.gz 便于按层读取。

L1 PaperAtom: 单篇科研闭环

01_initial_request

target / input / intent / quantifiable goal

02_agent_trajectory

thought / action / tool / observation / valid

03_success_verification

validation / metrics / final verdict

04_failure_modes

failed step / diagnosis / correction

规模

6,010 条 L1 PaperAtom ; 全部通过闭环 schema 校验。

动态过程

平均 trajectory steps: 8.2 ; 每步强制拆分 Background / Gap / Decision。

失败与修正

平均 failure_modes: 2.96 ; 把失败原因和修正动作作为可学习信号。

L2/L3: 论文间决策与领域演化链

L2 TransitionAtom

描述相邻论文 A->B 的科研决策：

- gap_in_A: 前作留下什么缺口
- hypothesis_for_B: 后作提出什么假设
- decision_rationale: 为什么选择该机制
- experimental_validation_in_B: 如何验证
- is_failure_recovery: 是否是失败恢复

论文边




L3 LineageTrajectory

把多篇论文组织成领域演化链：

- open_problem: 起始开放问题
- chain_trajectory: 每篇里程碑的角色
- remaining_gap: 每一步留下的后续问题
- chain_verdict: 当前领域状态

L4 AgenticEpisode: 科研 Agent 轨迹



训练价值


L4 将 search/read/extract/diff/propose 组织成 ReAct demo，可直接用于科研 Agent 的 SFT、DPO 或工具调用能力评测。

构建流水线



所有阶段均保留 provenance : 论文 ID、公开外部 ID、解析工具、抽取模型和构建时间戳。

MinerU 使用方式



复现路径

Cloud API 用于新增开放 PDF；本地 MinerU2.5-Pro pipeline 用于自托管批处理。每条 L1 记录都写入 parse_tool。

质量控制与合规

真实性

Prompt 明确禁止 invent facts；实验步骤来自真实论文全文或公开摘要。

合规

不访问付费墙内容；不重新分发原始 PDF；保留公开 ID 和 DOI/arXiv 链接。

安全

不含 PII；不含可执行载荷；敏感学科只保留公开方法学层面的结构化描述。

质量

Schema 校验、去重、抽样质检、审计统计和数据卡片公开。

Release 校验：L1/L2/L3/L4 valid 均为 100%，完整数据和审计统计随仓库一起提交。

提交内容与应用价值

提交包

GitHub 仓库 + 压缩包：
数据文件、38 条完整样例、10 条原始来源样例、schema
、技术报告、构建代码。

应用场景

科学推理训练、科研 Agent SFT、演化 RAG、Sci-Evo 风格
评测、跨学科方法迁移分析。

已有影响

L4 demo 已集成至 idea_train；相关 SFT 相比 baseline 提
升约 7 分。

仓库链接

<https://github.com/Geniusyingmanji/idea-data>
类型标注：Sci-Evo